

DEEP LEARNING: ADVANCED MODELS AND METHODS — DL26

Track 1 – Metric Learning for Face Recognition

Metric Learning per il Riconoscimento Facciale

Mattia Campanella · Gruppo G25

github.com/MattiaCampanella/ml-face-recognition

Come riconosci un volto che non hai mai visto?

Il limite dei classificatori tradizionali

Un modello addestrato su N identità non può generalizzare su identità **mai viste**: le feature sono ancorate alle classi di training, non alla geometria del volto.


La soluzione: Metric Learning

Impariamo $f : \mathcal{I} \rightarrow \mathbb{R}^{512}$ tale che:

$$d(f(x_i), f(x_j)) \ll d(f(x_i), f(x_k))$$

quando x_i, x_j sono la **stessa persona** e x_k è una **persona diversa**.

- ▶ Variazioni di posa, illuminazione, espressione
- ▶ Generalizzazione **zero-shot** su nuove identità
- ▶ Valutazione: **mAP@1 / @5 / @10** su identità unseen



Obiettivo di valutazione


mAP@1, @5, @10 su identità **unseen**
(retrieval: trova il volto più simile)

CASIA-WebFace: grande, ricco, e con un'insidia nascosta

Il Dataset

Caratteristica	Valore
Immagini totali	≈490.000
Identità uniche	≈10.000
Formato originale	MXNet RecordIO

Split per identità disgiunte (zero leakage):



Label Noise — problema critico

Studi scientifici (*Anti-noise*, CVPR) stimano in CASIA:

- ▶ **9.3%–13%** di sample rumorosi o errati
- ▶ **7.7%** di **mislabeled** effettivo


Impatto diretto sul training con hard mining: i falsi negativi avvelenano il gradiente.

Perché è critico?

Con hard mining il modello cerca attivamente i casi più difficili. Se sono rumorosi, distruggono il segnale di apprendimento — lo vedremo nella slide successiva.

Baseline: classificazione supervisionata come punto di partenza

Architettura




Risultati Baseline

Metrica	Score
mAP@1	$\approx 63.0\%$
mAP@5	$\approx 50.7\%$
mAP@10	$\approx 44.1\%$

Il limite concettuale


La Cross-Entropy ottimizza la separazione tra *classi note*. L'embedding risultante **non è ottimizzato** per il retrieval su identità unseen.



Ampio margine di miglioramento →
metric learning

Il metodo: Triplet Loss con PK Sampling e Online Hard Mining

La Tripletta



PK Sampling — batch efficaci:

- ▶ $P = 32$ identità $\times K = 4$ immagini/ID
- ▶ Batch effettivo: 128 immagini bilanciate

Online Mining batch-wise

1. Estrai embedding per il batch (128 immagini)
2. Calcola matrice distanze $D \in \mathbb{R}^{128 \times 128}$ (cosine)
3. Per ogni anchor seleziona:
 - **Hard positive**: positivo più lontano
 - **Hard negative**: negativo più vicino
4. Calcola la loss solo sui triplet difficili

Perché hard mining?

I triplet easy producono gradiente ≈ 0 :
il modello non impara nulla da essi.
Hard mining seleziona i casi più **informativi**.


Distanza usata: $d(u, v) = 1 - \langle u, v \rangle$ su embedding L2-normalizzati.

La formulazione della loss conta più del margine: soft batte hinge

[X] Hinge — instabile con label noise

$$\mathcal{L}_{\text{hinge}} = \max(0, d^+ - d^- + m)$$


Margine esplicito m : i mislabeled CASIA diventano falsi hard negative e **avvelenano il gradiente** → collasso del modello.



[OK] Softplus — robusta al rumore

$$\mathcal{L}_{\text{soft}} = \log(1 + e^{d^+ - d^-})$$


Nessun margine fisso: penalizzazione continua e proporzionale. Tollerante al noise → convergenza stabile.



Con il **13% di label noise** di CASIA, la formulazione *soft* non è solo migliore: è **necessaria** per la stabilità del training.

+24 p.p. di mAP@1: il metric learning supera nettamente il baseline

Modello	@1	@5	@10
Baseline (CE)	63.0%	50.7%	44.1%
Triplet Soft	87.0%	81.0%	77.0%
ArcFace	82.1%	74.6%	69.0%




Cosa emerge:

1. **+24 p.p.** di mAP@1 rispetto al baseline
2. Triplet Soft **supera ArcFace** di +4.9 p.p. @1
3. ArcFace comunque **+19 p.p.** vs baseline

Il vantaggio è frutto dell'interazione tra **soft loss** + **hard mining** + **PK(32,4)**, non di un singolo iperparametro.

Lo spazio latente si organizza: cluster compatti per identità

t-SNE degli embedding (Triplet Soft)



PCA degli embedding (Triplet Soft)



Cosa mostrano i plot:

- ▶ Cluster **compatti e separati** per identità
- ▶ Spazio coseno **ben strutturato** → retrieval efficace
- ▶ Rispetto al baseline: embedding più **dispersi e sovrapposti**

Le training curve confermano:

- ▶ **Softmargin**: d^- cresce stabilmente, d^+ si riduce gradualmente
- ▶ **Hingemargin**: d^+ diverge in corrispondenza dei sample rumorosi → collasso

Validazione qualitativa

L'analisi visiva corrobora i numeri di mAP:
le identità si separano nello spazio degli embedding
L2-normalizzati a 512 dimensioni

Conclusioni: soft mining + PK batch = +24 p.p. zero-shot

[OK] Messaggio principale

Il Triplet con **soft loss** e **PK(32,4)** porta il mAP@1 dal **63% all'87%**, superando anche ArcFace (+4.9 p.p.)

La chiave: la formulazione *soft* è più importante del valore del margine, specialmente con dataset rumorosi.

3 Takeaway concreti:

1. **Soft > Hinge** con label noise elevato:
il margine esplicito è instabile con CASIA
2. **PK(32,4) + hard mining** è il compromesso ottimale:
batch più piccoli portano a overfitting
3. **Hard mining è necessario**:
mining easy/semi crea un gap di oltre 17 p.p.

Limiti riconosciuti


- ▶ **Mislabeling CASIA** (7.7%–13%):
avvelena il gradiente con hard mining
- ▶ **Assenza di Face Alignment**:
no MTCNN/landmark cropping
→ variabilità non ridotta preventivamente

Lavoro futuro:

- ▶ Noise detection semi-supervisionata
- ▶ Sub-center ArcFace per cluster rumorosi
- ▶ Face alignment preprocessing (MTCNN)

Repository + demo Streamlit:

Demo live del modello disponibile online



clusteringdemo.vercel.app