

DEEP LEARNING: ADVANCED MODELS AND METHODS — DL26

Track 1 – Metric Learning for Face Recognition

Metric Learning per il Riconoscimento Facciale

Mattia Campanella · Gruppo G25

github.com/MattiaCampanella/ml-face-recognition

Come riconoscere un volto mai visto prima?

Il limite dei classificatori tradizionali

Un modello addestrato su N identità non può generalizzare su identità **mai viste**: le feature sono ancorate alle classi di training, non alla geometria del volto.


La soluzione: Metric Learning

Impariamo $f : \mathcal{I} \rightarrow \mathbb{R}^{512}$ tale che:

$$d(f(x_i), f(x_j)) \ll d(f(x_i), f(x_k))$$

quando x_i, x_j sono la **stessa persona** e x_k è una **persona diversa**.

- ▶ Variazioni di posa, illuminazione, espressione
- ▶ Generalizzazione **zero-shot** su nuove identità
- ▶ Valutazione: **mAP@1 / @5 / @10** su identità unseen




Obiettivo di valutazione

mAP@1, @5, @10 su identità **unseen**
(retrieval: trova il volto più simile)

Il Dataset

Caratteristica	Valore
Immagini totali	≈490.000
Identità uniche	≈10.000
Formato originale	MXNet RecordIO

Split per identità disgiunte (zero leakage):



zero identity overlap

Importanza Data Augmentation

La generalizzazione richiede variabilità nei dati:

- ▶ **Geometrica:** Crop, HorizontalFlip
- ▶ **Cromatica:** ColorJitter, Grayscale

Impatto diretto:


riduce drasticamente l'overfitting, astruendo le feature chiave dell'identità.

Perché è critica?

Simulando le variazioni ambientali (es. luci diverse, posa) forziamo la rete a ignorare dettagli irrilevanti e diventare invariante ai disturbi.

Baseline: classificazione supervisionata come punto di partenza

Architettura




Risultati Baseline

Metrica	Score
mAP@1	$\approx 63.0\%$
mAP@5	$\approx 50.7\%$
mAP@10	$\approx 44.1\%$


Il limite concettuale

La Cross-Entropy ottimizza la separazione tra *classi note*. L'embedding risultante **non è ottimizzato** per il retrieval su identità unseen.



Il metodo: Triplet Loss con PK Sampling e Online Hard Mining

La Tripletta



PK Sampling — batch efficaci:

- ▶ $P = 32$ identità $\times K = 4$ immagini/ID
- ▶ Batch effettivo: 128 immagini bilanciate
- ▶ Garantisce mining **ricco e stabile**

Online Mining batch-wise

1. Estrai embedding per il batch (128 immagini)
2. Calcola matrice distanze $D \in \mathbb{R}^{128 \times 128}$ (cosine)
3. Per ogni anchor seleziona:
 - **Hard positive**: positivo più lontano
 - **Hard negative**: negativo più vicino
4. Calcola la loss solo sui triplet difficili

Perché hard mining?

I triplet easy producono gradiente ≈ 0 :
il modello non impara nulla da essi.
Hard mining seleziona i casi più **informativi**.


Distanza usata: $d(u, v) = 1 - \langle u, v \rangle$ su embedding L2-normalizzati.

La formulazione della loss conta più del margine: soft batte hinge

Hinge + Semi-Hard stabile ma lenta

$$\mathcal{L}_{\text{hinge}} = \max(0, d(x_a, x_p) - d(x_a, x_n) + m)$$

Evita il collasso dovuto al label noise, ma la convergenza con margine rigido risulta più lenta e meno efficiente rispetto alla controparte soft.




Curve hinge + semi-hard mining: solido

SoftPlus + Hard Mining robusta al rumore

$$\mathcal{L}_{\text{soft}} = \ln(1 + e^{d(x_a, x_p) - d(x_a, x_n)})$$


Nessun margine fisso: penalizzazione continua e proporzionale. Tollerante al noise → convergenza stabile.



Curve softmax + hard mining: convergenza pulita

+24 p.p. di mAP@1: il metric learning supera nettamente il baseline

Modello	@1	@5	@10
Baseline	63.0%	50.7%	44.1%
Triplet (Hinge)	78.0%	69.0%	64.0%
Triplet (Soft)	87.0%	81.0%	77.0%
ArcFace (Naive)	83.9%	77.1%	71.8%



Cosa emerge:


1. **Triplet (Soft)** ottiene **+24 p.p.** di mAP@1 rispetto al baseline.
2. **Soft vs Hinge**: softmargin + hard-mining superano hinge + semi-hard di **+9 p.p.** @1.
3. **ArcFace (Naive)** supera Triplet (Hinge) di +5.9 p.p., ma cede a Triplet (Soft).

Il vantaggio di Triplet (Soft) è dovuto a: **soft loss** + **hard mining** + **PK(32,4)**.

Perché non possiamo ottimizzare Hinge con l'Hard Mining?

[Instabile] Hinge + Hard Mining


La combinazione impedisce una convergenza stabile, degradando lo spazio latente ($\text{mAP@1} \approx 25\%$).



- **Sensibilità agli Outlier:** L'hard mining seleziona negativi atipici o etichettati erroneamente (rumore/outliers) trattandoli come falsi negativi estremi.
- **Margine Rigido:** Hinge impone una penale e un gradiente costante su questi errori, corrompendo lo spazio.

[Stabile] Soft Margin + Hard Mining

Convergenza rapida e stabile ($\text{mAP@1} \approx 87\%$).



- **Gradiente Fluido:** La loss 'softplus' attenua in modo asintotico l'influenza dei campioni troppo difficili.
- **Robustezza Intrinseca:** Il modello tollera le anomalie senza indebolire la durezza del mining.

Conclusioni: soft mining + PK batch = +24 p.p. zero-shot

Messaggio principale

Il Triplet con **soft loss** e **PK(32,4)** porta il mAP@1 dal **63% all'87%**, superando anche ArcFace (+3.1 p.p.)

La chiave: la formulazione *soft* è più importante del valore del margine, specialmente con dataset rumorosi.

3 Takeaway concreti:

1. **Soft > Hinge** con label noise elevato:
il margine esplicito è instabile con CASIA
2. **PK(32,4) + hard mining** è il compromesso ottimale:
batch più piccoli portano a overfitting
3. **Hard mining è necessario**:
mining easy/semi crea un gap di oltre 17 p.p.


Limiti riconosciuti

- ▶ **Mislabeling CASIA** (7.7%–13%):
avvelena il gradiente con hard mining
- ▶ **Assenza di Face Alignment**:
no MTCNN/landmark cropping
→ variabilità non ridotta preventivamente

Lavoro futuro:

- ▶ Noise detection semi-supervisionata
- ▶ Face alignment preprocessing (MTCNN)

Demo live del modello disponibile online



clusteringdemo.vercel.app

BACKUP SLIDES

Approfondimenti e Analisi Dettagliate

Studio di Ablazione Completo

Data	Sampler	Dim	Loss	Margine	Mining	mAP@1	mAP@5	mAP@10
13/05	PK(24, 4)	128	Softmargin	–	hard	70.0%*	60.0%*	54.0%*
14/05	PK(24, 4)	512	Softmargin	–	hard	69.0%*	58.0%*	51.0%*
14/05	PK(24, 4)	512	Softmargin	–	easy	68.0%*	57.0%*	50.0%*
14/05	PK(32, 4)	512	Softmargin	0.1	semi-hard	72.0%	62.0%	56.0%
15/05	PK(32, 4)	512	Softmargin	–	hard	86.0%	80.0%	75.0%
15/05	PK(32, 4)	512	Softmargin[†]	–	hard	87.0%	81.0%	77.0%
16/05	PK(42, 4)	512	Softmargin [†]	–	hard	86.0%	80.0%	75.0%
16/05	PK(32, 4)	512	Hingemargin	0.1	hard	25.0%	16.0%	12.0%
30/05	PK(32, 4)	512	Hingemargin [†]	0.2	semi-hard	82.0%	75.0%	69.0%
03/06	PK(32, 4)	512	Hingemargin	0.2	semi-hard	78.0%	69.0%	64.0%

* Indica presenza di overfitting osservato durante il training. † L2 normalization non applicata durante il training.

Dettagli di Addestramento e Preprocessing

Setup di Ottimizzazione

Parametri e strategie per la stabilità del gradiente:

- ▶ **Ottimizzatore:** AdamW con $\eta = 3 \times 10^{-3}$ e weight decay = 10^{-2} .
- ▶ **Scheduler:** *CosineAnnealingLR* ($T_{\max} = 30$, $\eta_{\min} = 10^{-6}$).
- ▶ **Arresto Precoce:** Disabilitato nel run migliore; monitorato su `val_map@5`.
- ▶ **Gradient Clipping:** Max norm = 5.0 per contenere picchi di gradiente.

Preprocessing e Data Augmentation

Trasformazioni geometriche e cromatiche (solo training):

- ▶ **Risoluzione:** Resize a 256×256 , poi *RandomResizedCrop* a 224×224 (scale 0.8–1.0).
- ▶ **Augmentation:**
 - *RandomHorizontalFlip* ($p = 0.5$): invarianza speculare.
 - *ColorJitter*: brightness, contrast, saturation, hue.
 - *RandomGrayscale* ($p = 0.05$): robustezza cromatica.
- ▶ **Normalizzazione:** canali RGB su medie/std ImageNet.

Differenze Teoriche: Triplet Loss vs ArcFace

Triplet Loss: Confronto Relativo (Locale)

Ottimizza le distanze relative all'interno di mini-batch locali (tuple di 3 campioni).

- **Formulazione:** Spinge $d(x_a, x_p) \rightarrow 0$ e allontana $d(x_a, x_n)$ oltre un margine m :

$$\mathcal{L} = \max(0, d(x_a, x_p) - d(x_a, x_n) + m)$$

- **Spazio Latente:** Struttura locale flessibile; le classi non hanno un centro fisso e possono disperdersi.
- **Limiti:**
 - Complessità combinatoria delle triplette $O(N^3)$.
 - Richiede algoritmi di *mining* online complessi.
 - Sensibile al label noise locale.

ArcFace: Margine Angolare (Globale)

Approccio basato su classificazione softmax con margine additivo applicato geodeticamente sull'ipersfera unitaria.

- **Formulazione:** Modifica la logit inserendo un margine angolare m rispetto al peso-prototipo W_j :

$$\mathcal{L} = -\log \frac{e^{s \cos(\theta_{y_i} + m)}}{e^{s \cos(\theta_{y_i} + m)} + \sum_{j \neq y_i} e^{s \cos \theta_j}}$$

- **Spazio Latente:** Gli embedding sono proiettati su S^{d-1} . Le classi formano cluster iper-compatti attorno a prototipi globali W_j .
- **Vantaggi e Limiti:**
 - Nessun mining richiesto; training stabile.
 - Complessità lineare con le identità $O(N \cdot C)$.
 - Richiede molta memoria GPU per dataset con milioni di classi (C elevato).

ArcFace: Tentativi di Miglioramento della Robustezza

Ablation sul Margine Angolare m ($k=1$)

Fissati $s = 64$, $\eta = 10^{-4}$, backbone ResNet-18 pretrained.

m	mAP@1	mAP@5	mAP@10
0.5 (paper)	78.2%	69.8%	64.1%
0.3	82.1%	74.6%	69.0%

Osservazione: il margine $m = 0.5$ suggerito dal paper originale su CASIA è sub-ottimale con ResNet-18. Un margine ridotto ($m = 0.3$) produce embedding più stabili grazie alla minore pressione angolare con backbone più leggero.

Sub-Center ArcFace ($k = 3$) — Robustezza al Noise

Ogni classe ha k centri angolari anziché uno solo (Deng et al., 2020).

m	k	mAP@1	mAP@5
0.2	3	83.9%	77.1%
0.3	3	46.8%*	34.4%*
0.5	3	74.7%	65.4%

* Run anomalo (60 epoche): instabilità nel training prolungato.


- ▶ $k = 3$, $m = 0.2$: **picco ArcFace 83.9%**, ma sotto Triplet (Eng.) (87.0%).
- ▶ Riduce la penalità su campioni ambigui, ma instabile con margini ampi.
- ▶ **Conclusione:** $k > 1$ non compensa il gap vs. Triplet + hard mining.

Visualizzazione dello Spazio Latente: PCA

Baseline (CE)



Hinge + Semi-Hard




Triplet (Eng.) — Best



PCA (2 componenti principali) su un campione di 20 identità dal validation set. I colori rappresentano identità distinte.

Visualizzazione dello Spazio Latente: t-SNE



t-SNE ($\perp = 30, 1000$ iter.) su un campione di 20 identità dal validation set. I colori rappresentano identità distinte. Triplet (Eng.) mostra cluster nettamente separati rispetto al Baseline.